


Графовые нейросети и их применение

Обозначения



$G = (V, E)$, где

G — структура, которая состоит из двух множеств

V — множество вершин и их признаков

E — множество ребер и их признаков

$|V|$ - количество вершин

$|E|$ - количество ребер

u, v - вершины

d_u - степень вершины u

e_{uv} - признаки ребра, соединяющие вершины u, v

Self-Supervised Learning (SSL)

Почему появился Self-Supervised Learning?

моделям нужны огромные объёмы данных, но ручная разметка - дорогая, медленная и часто невозможная.

→ существует огромный разрыв между количеством “сырых данных” и количеством размеченных данных.

Self-supervised learning (SSL) появился как способ извлекать информацию из данных без разметки, создавая систематические *псевдо-задачи*, которые модель сама способна решать.

Иными словами:

SSL использует структуру данных, чтобы генерировать обучающие сигналы без участия человека.

Unsupervised VS Self-Supervised Learning

Unsupervised learning:

- изучает структуру данных напрямую,
- нет явно сформулированной задачи предсказания,
- примеры: кластеризация, PCA, обучение плотности.

Self-supervised learning:

- создаётся **искусственная supervised-задача** (pretext-task),
- у неё есть входы и "псевдо-лейблы", которые генерируются автоматически,
- цель - научить модель получать универсальные представления (embeddings).

Unsupervised VS Self-Supervised Learning

Классический пример:

BERT берёт текст и искусственно скрывает 15% слов.

Задача модели - предсказать скрытые слова.

Таким образом:

- мы используем искусственные лейблы,
- решаем реальную supervised-задачу,
- но делаем это без участия человека.

SSL ≠ просто кластеризация.

SSL - это **supervised learning** без человеческих меток.

Как SSL формирует обучающие сигналы?

Идея: Если модель знает, как восстановить недостающую часть данных, она вынуждена понимать структуру данных глубоко.

Примеры:

В NLP

- Masked Language Modeling (MLM)
- Next Sentence Prediction (BERT)
- Autoregressive prediction (GPT)

В Computer Vision

- Маскирование патчей (MAE)
- Контрастивные аугментации (SimCLR)
- Предсказание вращения изображения (RotNet)

В аудио

- wav2vec, предсказание будущих сегментов аудио

Как SSL формирует обучающие сигналы?

В графах

- Предсказание маскированных узлов или рёбер
- Контрастивное обучение представлений подграфов
- Предсказание структурных инвариантов

Основная философия SSL

Фундаментальная идея SSL: **Сильные модели требуют не разметки, а разнообразных способов "смотреть" на данные.**

SSL заставляет модель:

- сравнивать части данных между собой,
- восстанавливать пропущенные компоненты,
- понимать структурные зависимости,
- учиться инвариантности к определённым преобразованиям,
- выделять стабильные, переносимые (transferable) признаки.

SSL не обучает модель выполнять конкретную задачу,

SSL обучает модель понимать данные.

Поэтому SSL - фундамент большинства foundation models

Почему SSL работает так хорошо?

1. Большие модели = большие пространства признаков

Чтобы модель смогла понимать данные, она должна научиться:

- хранить информацию,
- извлекать структуру,
- различать важные факторы вариации.

SSL создаёт тысячи полезных задач, которые вынуждают модель учиться богатым представлениям.

Почему SSL работает так хорошо?

2. SSL максимизирует взаимную информацию (informally)

Многие SSL-подходы можно интерпретировать как максимизацию взаимной информации:

- между разными представлениями объекта,
- между локальными и глобальными признаками,
- между частями данных.

Это приводит к представлениям:

- устойчивым,
- инвариантным,
- информативным,
- переносимым.

Почему SSL работает так хорошо?

3. SSL создаёт inductive biases, которых нет в supervised обучении

Supervised обучение учится только тому, что связано с задачей классификации (или регрессии).

SSL же вынуждает понимать всю структуру данных.

Поэтому SSL-представления:

- лучше обобщают,
- лучше переносятся между задачами,
- устойчивее к шуму и adversarial-атакам,
- работают даже при минимальном количестве меток.

Почему SSL стало стандартом в NLP, CV и Graph ML?

Потому что оно отвечает на главный вопрос современной архитектуры моделей:

Как использовать огромные объёмы неразмеченных данных?

SSL позволяет **обучить универсальные представления**, которые затем легко дообучаются на маленьких размеченных датасетах.

Примеры:

- BERT после SSL обгоняет модели, обученные только supervised.
- ViT плохо работает без SSL, но с MAE становится state-of-the-art.
- В графах SSL позволяет получить модели, которые превосходят supervised даже при наличии всех меток.

Парадигмы Self-Supervised Learning

Основные категории задач SSL

1. Contrastive SSL

Идея: одинаковые объекты → близкие embeddings; разные объекты → далеко.

Методы: *SimCLR*, *MoCo*, *GraphCL*.

2. Predictive / Masked SSL

Маскирование и восстановление.

Методы: *BERT*, *MAE*, *GraphMAE*.

3. Non-Contrastive SSL

Без негативных примеров, обучение через teacher–student.

Методы: *BYOL*, *SimSiam*, *DINO*, *BGRL* (графы).

4. Clustering-based SSL

Пространство embeddings организуется через прототипы.

Методы: *SwAV*, *DINO*.

Contrastive Learning

Базовая интуиция контрастивного SSL

Контрастивное обучение основано на двух понятиях:

(1) Положительные пары (positive pairs)

Это два «представления» одного и того же объекта.

Например:

- две аугментации одного изображения,
- два обрезанных подграфа исходного графа,
- два вида одного аудиосигнала,
- оригинальное и dropout-passage в NLP.

Обозначим такую пару как:

$$(x, x^+)$$

(2) Отрицательные пары (negative pairs)

Это пара объектов, которые **должны быть различны** в embedding-пространстве.

$$(x, x^-)$$

Базовая интуиция контрастивного SSL

Цель:

Научить модель такому отображению:

$$f(x) \approx f(x^+), \quad f(x) \not\approx f(x^-)$$

То есть приближать положительные пары и раздвигать отрицательные.

Самая важная часть контрастивного SSL — функция потерь InfoNCE.

Мы хотим максимизировать:

$$\text{sim}(z, z^+)$$

и минимизировать:

$$\text{sim}(z, z^-)$$

где $z = f(x)$

Эlegantная формула InfoNCE:

$$\mathcal{L} = -\log \frac{\exp\left(\frac{\text{sim}(z_i, z_i^+)}{\tau}\right)}{\sum_{k=1}^K \exp\left(\frac{\text{sim}(z_i, z_k)}{\tau}\right)}$$

Здесь:

- $\text{sim}(\cdot, \cdot)$ - обычно cosine similarity,
- τ — температура, регулирующая “жесткость” распределения,
- знаменатель содержит **все отрицательные примеры**.

Базовая интуиция контрастивного SSL

Где берутся негативы?

На практике есть три подхода:

1. Negatives = весь batch

SimCLR требует огромного batch size (до 8192), чтобы количество негативов было достаточно большим.

2. Memory bank / queue

MoCo использует очередь, где хранятся embeddings из предыдущих шагов.

Преимущество:

не нужно делать огромные батчи → ускоряется обучение.

3. In-batch negatives + hard negatives

Некоторые методы специально ищут «сложные» негативы (hard negatives), которые ближе всего к положительным.

Базовая интуиция контрастивного SSL

Почему InfoNCE работает?

Контрастивное обучение - это не просто "раздвигание" точек. У него есть глубокое теоретическое обоснование.

(1) InfoNCE максимизирует оценку взаимной информации (MI)

Оказывается, можно показать:

$$I(x; x^+) \geq -E[\mathcal{L}_{InfoNCE}]$$

То есть **минимизация InfoNCE $\approx$ максимизация нижней оценки взаимной информации** между двумя представлениями.

Модель учится представлять такие факторы данных, которые устойчивы "под преобразованиями".

Базовая интуиция контрастивного SSL

Почему InfoNCE работает?

Контрастивное обучение - это не просто "раздвигание" точек. У него есть глубокое теоретическое обоснование.

(2) InfoNCE создаёт инвариантность

Если аугментации делают объект «разным», но модель должна сделать embeddings одинаковыми, это заставляет её:

- игнорировать шум,
- абстрагироваться от изменений в изображении/графе,
- выучивать более семантические признаки.

(3) InfoNCE создаёт разделимость классов

Если объект должен отличаться от всех негативов, то модель разворачивает embedding-пространство так, чтобы каждый объект был «кластером». Это объясняет, почему SimCLR даёт такие хорошие классификационные фичи.

Роль аугментаций

Контрастивное обучение - это не только loss.

Это обучение **инвариантности к определённым преобразованиям**.

Примеры:

- в CV - cropping, color jitter, blur;
- в NLP - dropout, составные единицы;
- в графах - node dropping, edge perturbation, subgraph sampling.

Хорошие SSL-аугментации = модель учится семантике.

Плохие аугментации = модель учится шуму.

Аугментации - это **центральный элемент** контрастивного метода.

Основные проблемы контрастивного SSL

Проблема 1. Нужно много негативов

Нельзя просто взять batch=32: модель быстро коллапсирует.

SimCLR показал, что для хорошего качества нужны batch size 4096–8192.

Проблема 2. Слишком сильная зависимость от аугментаций

Если аугментации слишком агрессивные, positive pairs становятся несвязными.

Если слишком слабые - embeddings становятся тривиальными.

Проблема 3. Отрицательные пары могут быть ложными

В графах два подграфа могут быть разными представлениями одной и той же структуры.

В NLP две фразы могут быть перефразами.

Но InfoNCE заставляет отталкивать их как негативы → ухудшение качества.

Проблема 4. Collapse risk (но реже)

Если негативов мало, модель может «схлопнуться» в константу.

Self-Supervised Learning без негативных примеров (Non- Contrastive SSL)

Эволюция SSL

почему появились BYOL и SimSiam

Проблемы контрастивных методов привели к появлению **non-contrastive SSL**, где:

- нет негативов,
- нет огромных батчей,
- нет memory bank.

BYOL, SimSiam и VICReg возникли как ответ на ограничения контрастивных подходов.

Почему обучение без негативов — это вызов?

Если убрать отрицательные пары, возникает тривиальное решение:

$$f(x) = c \text{ для всех } x$$

и loss становится минимальным.

То есть модель может «схлопнуться» в константу.

И все 20 лет до BYOL считали, что **без негативов контрастивное обучение невозможно**.

Методы, которые мы обсудим, обходят этот парадокс тремя ключевыми механизмами:

1. **Разрыв градиента (stop-gradient)**
2. **Два представления одной сети: online и target**
3. **Статистические ограничения на variance и covariance**

Non-Contrastive SSL

(парадигма, убирающая негативные примеры)

Главная идея: Учить модель так, чтобы два представления одного объекта были одинаковыми, **но без отрицательных примеров.**

Секрет — специальные архитектурные и статистические ограничения, предотвращающие коллапс.

Общая схема

Есть:

- **online network** f_{θ}
- **target network** f_{ξ}

Мы оптимизируем:

$$L = \| f_{\theta}(x_i) - \text{stopgrad}(f_{\xi}(x_j)) \|^2$$

Target-сеть обновляется EMA-обновлением:

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta$$

BYOL — Bootstrap Your Own Latent

(2020, Google DeepMind) BYOL стал первым успешным методом, доказавшим, что SSL без негативов возможно.

Идея

Создаются две сети:

- **online network** f_θ
- **target network** f_ξ

Обе получают две аугментации одного объекта:

$$x \rightarrow x_1, x_2$$

online-сеть должна предсказать представление target-сети:

$$z_1 = f_\theta(x_1) \quad z_2 = f_\xi(x_2)$$

Loss:

$$L = \| z_1 - \text{stopgrad}(z_2) \|^2$$

Ключевой элемент — **stop-gradient**: через target-сеть градиент не течёт.

Target-сеть обновляется по EMA:

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta$$

SimSiam — простой метод без momentum encoder

(FAIR, 2021)

SimSiam показал, что даже momentum encoder **не обязателен** для предотвращения коллапса.

Идея

Две одинаковые сети f , одна часть получает stop-gradient:

$$\mathcal{L} = -\cos(p_1, \text{stopgrad}(z_2)) - \cos(p_2, \text{stopgrad}(z_1))$$

где $p = \text{predictor}(z)$

Статистические методы

Barlow Twins (2021)

Основная идея — сделать кросс-корреляционную матрицу близкой к единичной:

$$L = \sum_i (1 - c_{ii})^2 + \lambda \sum_{i \neq j} c_{ij}^2$$

- диагональ → инвариантность,
- внедиагональные элементы → decorrelation.

Это заставляет признаки быть разнообразными.

Статистические методы

VICReg (2022)

Variance–Invariance–Covariance Regularization.

Loss состоит из трёх частей:

1. Invariance:

$$\|z_1 - z_2\|^2$$

2. Variance:

поощрение разброса представлений

3. Covariance:

подавление избыточных корреляций

VICReg стал мощной и стабильной альтернативой contrastive learning.

Unified intuition: почему эти методы работают?

Несмотря на кажущиеся различия, у всех non-contrastive SSL есть единая формула успеха:

1. Инвариантность (invariance):

представления должны совпадать для аугментаций.

2. Разнообразие (variance):

представления должны заполнять пространство, не коллапсировать.

3. Декорреляция (covariance):

разные координаты embedding-а должны не дублировать друг друга.

Contrastive методы обеспечивают эти свойства автоматически (через негативы).

Non-contrastive методы обеспечивают их *архитектурно* или *статистически*.

Masked Self-Supervised Learning (Masked Modeling)

Общая идея Masked Modeling

Возьмём входные данные x .

Сформируем маску M , скрыв часть данных:

$$x_{visible} = x \odot (1 - M), \quad x_{masked} = x \odot M$$

Encoder получает только **частично наблюдаемый** вход.

Decoder пытается восстановить скрытую часть:

$$\hat{x}_{masked} = g(f(x_{visible}))$$

Loss — это расстояние до оригинала:

$$\mathcal{L} = \| \hat{x}_{masked} - x_{masked} \|^2$$

Predictive / Masked Modeling

Примеры задач

1. Masked Language Modeling (MLM)

В BERT маскируют 15% токенов:

$$x = (w_1, w_2, [MASK], w_4, \dots)$$

Модель предсказывает скрытый токен:

$$p(w_{mask} | x)$$

2. Masked Image Modeling (MAE)

Визуальный аналог MLM:

- изображение режется на патчи,
- 75% патчей убираются,
- модель восстанавливает пиксельное содержимое.

Masked Image Modeling (MIM) — MAE

Особенность MAE:

- маскируется **75%** PATCH-ов,
- encoder работает только с 25%,
- decoder восстанавливает полный пиксельный вид.

Почему 75%?

- потому что ViT легко восстанавливает большие патчи,
- модель учится семантическим признакам, а не пиксельным деталям.

Структура MAE:

- **encoder**: ViT, работает быстро, на части изображения,
- **decoder**: простой, срабатывает только на reconstruction loss.

MAE стал революцией:

- ViT, который без SSL работал плохо, стал одним из лучших vision-моделей;
- MIM оказался стабильнее SimCLR/SimSiam;
- обучение MAE масштабируется практически линейно.

Predictive / Masked Modeling

Плюсы

- Работает без негативных примеров.
- Легче стабильно обучается.
- Отлично масштабируется (MAE обучает ViT на ImageNet-1K за часы).
- Дает *универсальные* репрезентации.

Минусы

- Может переучиться "на низком уровне" (pixel recovery $\neq$ semantic).
- Требуется decoder-а, который иногда замедляет обучение.

Почему Masked SSL работает так хорошо?

Есть три ключевых причины:

1. Masked tasks заставляют модель понимать структуру данных

Чтобы восстановить пропущенную информацию:

- BERT должен понимать синтаксис и смысл,
- MAE должен понимать форму объектов,
- GraphMAE должен понимать локальную топологию.

Это **обучение на структуре**, а не просто на шуме.

2. Маскирование создаёт естественные supervisory signals

Loss в masked моделях:

- не требует негативов,
- не требует батчей размера 4096,
- не зависит от чувствительных аугментаций.

Это стабильный, естественный способ обучения.

Почему Masked SSL работает так хорошо?

Есть три ключевых причины:

3. Маскированные модели = генеративные модели частичной информации

MAE, GraphMAE, BERT — фактически генеративные модели:

$$p(x_{masked} | x_{visible})$$

Это ближе к плотностному моделированию, чем contrastive learning.

Clustering-Based SSL

Clustering-Based SSL

Главная идея: Модель одновременно:

1. учится получать embeddings,
2. учится распределять их по **кластерным центрам (прототипам)**.

Общая схема SwAV

Для объекта создаются две аугментации:

$$x \rightarrow x_1, x_2$$

encoder даёт:

$$z_1 = f(x_1), z_2 = f(x_2)$$

Обе проекции назначаются в один и тот же кластер:

$$q_1 = \text{assign}(z_1), \quad q_2 = \text{assign}(z_2)$$

оптимизация заставляет сеть согласовывать их:

$$\mathcal{L} = CE(q_1, \text{softmax}(Wz_2))$$

Кластеры обновляются online.

Clustering-Based SSL

Плюсы

- Нет негативных примеров.
- Более глобальное понимание структуры данных.
- Хорошо работает в больших моделях.

Минусы

- Реализация сложнее.
- Появляется риск коллапса без careful normalization.

Self-Supervised Learning на графах (Graph SSL)

Почему SSL так важно для графов?

В отличие от изображений или текста, у графов есть особенности:

1. Мало лейблов

В молекулах метка = результат химического эксперимента.

Всего пару тысяч меток → обучать глубокую сеть сложно.

2. Много структурной информации, которую supervised обучение игнорирует

Степени, циклы, роли узлов, симметрии, спектр, подграфы —
всё это можно извлечь без меток.

3. Графы разнообразны

Даже в одном датасете графы могут сильно отличаться по размеру, форме и типам.

4. SSL в графах улучшает generalization гораздо сильнее, чем supervised

Это подтверждено в OGB (Open Graph Benchmark) — SSL повышает качество на 5–20%.

Виды аугментаций для графов

1. Node Dropping (удаление узлов)

Удаляем случайные узлы, сохраняя общую структуру.

Инвариантность: модель должна понимать граф, даже если небольшая часть его элементов недоступна.

2. Edge Dropping / Edge Perturbation

Удаление или модификация рёбер.

Это аналог обрезки контуров или текстуры в CV.

3. Subgraph Sampling

Мы выбираем компактный подграф вокруг центрального узла.

Важно: модель должна понимать общую структуру даже из частного наблюдения.

Используется в:

- GraphSAGE,
- MVGRL.

Виды аугментаций для графов

4. Attribute Masking

Маскируются фичи узлов или рёбер.

Аналог BERT/MAE → GraphMAE.

5. Diffusion / Graph Filtering

Применение спектральных фильтров или графовых преобразований к структуре.

Близко к MVGRL.

6. Structural Aware Augmentation

Используются редкие структурные элементы графа:

циклы, мосты, треугольники → инвариантность к локальной вариации топологии.

Contrastive Graph Learning

Теперь рассмотрим контрастивные методы на графах.

Они используют идею "двух видов графа":

$$G \rightarrow^{t_1, t_2} G_1, G_2$$

где t_1, t_2 — две независимые аугментации.

Задача:

$$f(G_1) \approx f(G_2), \quad f(G_1) \approx f(G^-)$$

Contrastive Graph Learning

GraphCL (ICML 2020)

Один из первых и важнейших методов Graph SSL.

Идея:

1. Генерируем два подграфа через разные аугментации.
2. Пропускаем оба через GNN.
3. Минимизируем InfoNCE между ними.

Аугментации:

- node dropping
- edge perturbation
- attribute masking
- subgraph sampling

На практике GraphCL дал крупнейший скачок качества на MUTAG, NCI1, OGB datasets.

Contrastive Graph Learning

MVGRL (2020)

Ещё один важный контрастивный метод.

Идея:

Сравниваются:

- глобальные представления графа,
- локальные представления узлов,
- плюс представления из альтернативного вида графа (диффузионного).

То есть:

$$\text{contrast}(h_{node}, h_{global}, h_{diffusion})$$

MVGRL — пример multi-view SSL.

Non-Contrastive Graph SSL (bootstrap)

BGRL (2021)

Bootstrap Graph Representation Learning

Это BYOL для графов.

$$f_{\theta}(G_1) \approx \text{stopgrad} \left(f_{\xi}(G_2) \right)$$

Сети (Те же элементы, что в BYOL, но с GNN вместо CNN.):

- online encoder
- target encoder (EMA)
- predictor

Почему BGRL важен?

- работает **без негативов**,
- требует только двух аугментаций,
- очень стабилен,
- достигает качества выше GraphCL на многих датасетах.

Non-Contrastive Graph SSL (bootstrap)

GraphVICReg (2022)

Аналог VICReg:

$$\mathcal{L} = invariance + variance + covariance$$

Много работ показывают, что VICReg-подходи особенно хорошо работают на больших графах.

GBT (Graph Barlow Twins)

Использует корреляционную матрицу между представлениями.

Эта группа методов — будущее Graph SSL, так как они:

- проще,
- стабильнее,
- не используют негативы,
- дают лучшие embeddings.

Маскирование на графах: GraphMAE

Теперь переносим идею MLM и MAE на графы.

Основная идея:

Маскируем часть узловых признаков:

- атомные признаки (в химии),
- категориальные признаки узлов в социальных графах,
- текстовые признаки в knowledge graphs.

Encoder получает граф с пропущенными атрибутами:

$$G_{masked} = (X_{visible}, A)$$

Decoder восстанавливает скрытое:

$$\hat{X}_{masked} = g(f(G_{visible}))$$

Loss:

$$\mathcal{L} = \| \hat{X}_{masked} - X_{masked} \|^2$$

Маскирование на графах: GraphMAE

Почему работает?

Графовая структура помогает восстанавливать скрытые признаки:

- узлы с похожим окружением → похожие признаки,
- локальная топология помогает infer-ить отсутствующее,
- GNN encoder учит общую структуру графа.

GraphMAE (а также GraphMAE2, GTAE) стали одними из ведущих подходов в академических бенчмарках.

Сравнение SSL-подходов + практические рекомендации

Контрастивное обучение для графов

Контрастивные методы стали первыми по-настоящему успешными подходами SSL в Graph ML:

- **GraphCL**
- **InfoGraph**
- **MVGRL**
- **Deep Graph Infomax (DGI)** (частично contrastive)

ИТОГОВЫЕ ВЫВОДЫ

SSL на графах - это полноценная самостоятельная область, в которой:

- **contrastive** = лучше для структурных задач;
- **bootstrap** = лучше для стабильности и масштабируемости;
- **masked** = лучше для атрибутивных графов и больших моделей.

Все три подхода дополняют друг друга и составляют базу **Graph Foundation Models**.